

Machine Learning: clasificación binaria

HUGO GÓMEZ SABUCEDO

hugogomezsabucedo@gmail.com

Máster Big Data, Data Science & Inteligencia Artificial

Curso 2024-2025

Universidad Complutense de Madrid

1. Introducción y análisis inicial

En este trabajo, se nos proporciona un archivo con datos de ventas de coches de segunda mano, en el que se recogen diferentes características de los mismos, provenientes de una empresa de coches de segunda mano que debe determinar el color óptimo con el que repintar algunos vehículos que han llegado en un estado deficiente. El objetivo es realizar, para la empresa que nos proporciona los datos, un modelo predictivo que, en base a las características y variables, determine si el vehículo debe pintarse de blanco o no.

Las características que se recogen para los vehículos son: el precio, el Levy o impuesto, el fabricante, el año de producción, la categoría, si el interior es o no de cuero, el tipo de combustible, el volumen del motor, el kilometraje, el número de cilindros, el tipo de caja de cambios, la tracción, el lado en donde se encuentra el volante y el número de airbags. Estas serán las variables predictoras que empleemos en nuestro modelo. Además, evidentemente, tenemos la variable color, que nos indica si el coche se pinta de blanco o negro, que será la variable que nos interese predecir.

1.1. Análisis de los datos. Feature engineering

En primer lugar, cargaremos el archivo en pandas, y el primer análisis que realizamos es ver la forma del dataframe y las cinco primeras columnas. Vemos que tenemos un dataframe con 15 columnas, tantas como variables habíamos comentado, y 4340 filas, y analizamos algunas de ellas para tener una idea de como son los datos y qué pasos podríamos seguir. El siguiente paso será ver si hay valores duplicados, y en este caso vemos que tenemos un total de 1534 valores duplicados. Es una gran proporción de los datos, en torno a un 35 % de los mismos, aunque en este caso se ha optado por eliminarlos. Es una decisión drástica, ya que suponen una gran parte de los datos, pero se ha tomado debido a que se considera que lo que pueden aportar al modelo es menos de lo que lo entorpecen. Hay que tener en cuenta que, si se detectan como duplicados, es que tienen el mismo valor en exactamente todas las variables (precio, kilometraje, Levy, etc.), lo cual de por sí ya es una situación difícil de encontrar. Esto ya no sólo aporta información redundante, y que podría alterar las estadísticas, sino que podría causar problemas de sesgo en el modelo resultante. Nuestro modelo se entrenará buscando patrones. Por tanto, la presencia de datos duplicados hará que ese patrón aparezca varias veces, lo cual hará que el modelo se sobreajuste a ello, produciéndose lo que se conoce como *overfitting*. Por tanto, se decide eliminar todos los duplicados, para prevenir este problema.

A continuación, vemos los tipos que se han asignado a las diferentes columnas. Vemos que únicamente se asignan como numéricas el precio, año de producción, cilindros e airbags. De momento, no haremos ninguna corrección, ya que realizaremos posteriormente algunas transformaciones sobre las columnas que modificarán su tipo.

Price	int64
Levy	object
Manufacturer	object
Prod. year	int64
Category	object
Leather interior	object
Fuel type	object
Engine volume	object
Mileage	object
Cylinders	int64
Gear box type	object
Drive wheels	object
Wheel	object
Color	object
Airbags	int64

Hacemos un describe inicial, para las variables que ha determinado como numéricas, donde vemos que el precio quizás tiene una ligera asimetría positiva, ya que su media es de 23.913 y su mediana

Figura 1: dtypes de las columnas

	Price	Prod. year	Cylinders	Airbags
count	2806.000000	2806.000000	2806.000000	2806.000000
mean	23913.585531	2012.811475	4.646472	7.536707
std	26028.717701	3.926385	1.281613	4.208459
min	3.000000	1943.000000	1.000000	0.000000
25%	9408.000000	2011.000000	4.000000	4.000000
50%	18821.500000	2013.000000	4.000000	8.000000
75%	31361.000000	2015.000000	4.000000	12.000000
max	627220.000000	2020.000000	12.000000	16.000000

Figura 2: Describe inicial

de 18.821, inclinada un poco hacia valores más altos. Además, el máximo es muy superior al cuartil 75 (627.220 frente a 31.361). Además, la desviación típica es relativamente elevada, de 26.028, lo cual nos indica que claramente la variable está distribuida de forma asimétrica. Posteriormente, trataremos este caso. Si hacemos un conteo de los valores missing, con un `isnull` y un `isnan`, vemos que no hay ninguna variable con valores faltantes, lo cual simplificará posteriormente el proceso.

Price	915
Levy	203
Manufacturer	4
Prod. year	29
Category	3
Leather interior	2
Fuel type	3
Engine volume	58
Mileage	1826
Cylinders	10
Gear box type	2
Drive wheels	3
Wheel	2
Color	2
Airbags	16
dtype: int64	

Figura 3: Valores únicos en las columnas

El siguiente paso es analizar los valores únicos que hay en las columnas, para ver si, para las variables categóricas, podemos modificar o reagrupar algunas. En este caso, vemos que hay variables con pocos valores únicos. Únicamente hay dos en *Leather interior*, *Gear box type*, *Wheel* y, como es de esperar, en *Color*; con tres, tenemos *Category*, *Fuel type* y *Drive wheels*; y con cuatro, únicamente *Manufacturer*. En el caso de las que únicamente tienen dos valores, realizaremos una conversión o mapeo binario. En el caso de *Leather interior*, mapearemos el Sí como un 1 y el No como un 0. Para *Color*, White será un 1 y Black un 0. Para *Wheel*, mapearemos 'Right-hand drive' a 1 y 'Left wheel' a 0, y renombraremos la columna como *Right wheel*; para *Gear box type*, mapearemos 'Automatic' a 1 y 'Triptonic' a 0, y renombraremos la columna a *Automatic*.

A continuación, modificaremos la variable *Engine volume*, para cambiar también su tipo. Se ha visto que, para algunos casos, la variable incluye el texto *Turbo*, por lo que se decide emplear un `str.contains()` para detectar aquellas filas en las que esto ocurre. Esto se llevará a una nueva columna, llamada *Turbo*, que nos indique si efectivamente el motor es Turbo o no. Ya que es una variable binaria, la mapearemos como 1 en caso de que lo sea, y 0 en caso de que no. Así, la variable *Engine volume* quedará como una variable numérica, conteniendo solo el volumen del motor.

Siguiendo con la limpieza, se corrige la variable *Mileage* para que pase a ser numérica, eliminando el texto 'km' que contenía el mismo, y convirtiéndola a entera. Respecto a la variable *Levy*, se ha visto que tiene el valor '-' en muchos casos, que podría indicar que ese coche en cuestión no tiene impuesto. En este caso, se ha decidido imputar este valor como un 0, manteniendo el valor original que hubiera en el resto de los casos. Esto nos permitirá tratar también esta variable como numérica, que es efectivamente el tipo de datos que debería tener.

Más allá de este caso particular, se analizó todo el dataset en búsqueda de valores faltantes.

Aunque el análisis inicial no mostraba nulos explícitos, tras las transformaciones era necesario asegurar que no quedaban valores vacíos en ninguna variable. Aunque se comprobó que esto no era así, se ha decidido incluir igualmente el fragmento de código por si se diera el caso de que se añadieran más datos que si que hicieran necesaria la imputación. Para las variables categóricas, se imputa una categoría adicional "Missing", lo que preserva la existencia de los registros sin introducir sesgo por asignar una categoría arbitraria. Para las variables numéricas, se opta por imputar con la mediana, una medida robusta frente a valores extremos que evita que los outliers distorsionen la distribución.

Con todo esto, podemos definir nuestras variables numéricas y categóricas, que quedan de la siguiente forma:

```
nums = ['Price', 'Prod. year', 'Leather interior', 'Engine volume', 'Mileage', 'Airbags', 'Cylinders', 'Right wheel', 'Automatic', 'Turbo', 'Levy']
cats = ['Manufacturer', 'Category', 'Fuel type', 'Drive wheels']
target = "Color"
```

A continuación, analizaremos las variables categóricas, viendo la distribución de las categorías, para ver si es necesario reclasificar. En el caso de la variable *Manufacturer*, tenemos un 37 % de coches de Hyundai, un 36,4 % de Toyota, un 18,4 % de Mercedes y un 8,2 % de Lexus. Esta última categoría podría estar poco representada, pero se ha decidido no hacer una reagrupación ya que puede resultar interesante dejar los datos como están. Además, la decisión lógica sería agruparla con los coches de Mercedes, lo cual no tiene mucho sentido, al tratarse de una marca de gama superior, para la cual es esperable que los coches, aún siendo de segunda mano, tengan un valor económico superior.

En el caso de *Category*, tenemos un 52,7 % de coches sedán, un 23 % de jeep y un 14,6 % de hatchback. En este caso, no hay ninguna categoría que tenga menos de un 10 % de los valores, por lo que no es necesario reagrupar. Las categorías no están distribuidas uniformemente, pero es algo que puede ser normal. En el caso de *Fuel type*, un 55,5 % de coches son de gasolina, un 23 % son híbridos y un 21,5 % son diésel. De nuevo, ninguna categoría es inferior al 10 %. Vemos que la mayoría de los coches son de gasolina pero, teniendo en cuenta que son datos de EEUU, donde este tipo de coches es el habitual, no parece raro.

Por último, tenemos *Drive wheels*, donde vemos que un abrumador 71,6 % tiene tracción delantera, un 18,4 % es 4x4 y un 9,9 % es de tracción trasera. En este caso, si que se hace una reagrupación, ya que claramente hay una categoría predominante. Se ha decidido agrupar los vehículos de 4x4 con los de tracción trasera. Esta reagrupación nos dejaría, además, una variable binaria, por lo que la renombramos como *Front drive*, donde un 1 significará la tracción delantera, mientras que un 0 significará que no tiene tracción delantera (bien sea porque es 4x4 o porque es de tracción trasera).

El siguiente paso es la búsqueda de outliers. En la imagen 4 se pueden ver los descriptivos de cada una de las variables numéricas, que ahora son más que las analizadas inicialmente. Algunos casos destacables que vemos es el precio, con un máximo relativamente alto. Sin embargo, para esta variable, hemos decidido no hacer ninguna imputación, ya que se entiende que un precio muy elevado podría tratarse de algún vehículo histórico, o con algunas características especiales o únicas, que justificaran este precio. El año de producción tiene dos valores claramente atípicos,

	Price	Levy	Prod. year	Leather interior	\
count	2806.000000	2806.000000	2806.000000	2806.000000	
mean	23913.585531	696.982537	2012.811475	0.805061	
std	26028.717701	582.894805	3.926385	0.395225	
min	3.000000	0.000000	1943.000000	0.000000	
25%	9488.000000	394.000000	2011.000000	1.000000	
50%	18321.500000	749.000000	2013.000000	1.000000	
75%	31361.000000	930.000000	2015.000000	1.000000	
max	627220.000000	11714.000000	2020.000000	1.000000	

	Engine volume	Mileage	Cylinders	Color	Airbags	\
count	2806.000000	2.806000e+03	2806.000000	2806.000000	2806.000000	
mean	2.379651	5.217066e+05	4.646472	0.487527	7.536707	
std	0.902089	2.097346e+07	1.281613	0.499933	4.208459	
min	0.000000	0.000000e+00	1.000000	0.000000	0.000000	
25%	1.000000	6.252075e+04	4.000000	0.000000	4.000000	
50%	2.000000	1.136000e+05	4.000000	0.000000	8.000000	
75%	2.500000	1.651665e+05	4.000000	1.000000	12.000000	
max	6.300000	1.111111e+09	12.000000	1.000000	16.000000	

	Right wheel	Automatic	Turbo	Front drive
count	2806.000000	2806.000000	2806.000000	2806.000000
mean	0.034212	0.772630	0.063435	0.716322
std	0.181807	0.419208	0.243788	0.450863
min	0.000000	0.000000	0.000000	0.000000
25%	0.000000	1.000000	0.000000	0.000000
50%	0.000000	1.000000	0.000000	1.000000
75%	0.000000	1.000000	0.000000	1.000000
max	1.000000	1.000000	1.000000	1.000000

Figura 4: Descriptivos

ya que el mínimo es de 1943, mientras que vemos que el resto de años son en torno a la década de los 90. Además, en la figura 5, vemos que en 1986 tenemos otro valor atípico. Los eliminaremos directamente ya que se trata únicamente de dos registros. Se ven también unos cuantos datos que podrían ser atípicos en la década de los 90, pero hemos decidido dejarlos, ya que consideramos que pueden aportar al modelo tener unos coches un poco más "antiguos".




Figura 5: Boxplot de año de producción

Respecto a *Engine volume*, tenemos un mínimo de 0, un valor que se repite en dos registros. Esta variable se refiere a la cilindrada del coche, que en ningún caso puede ser 0. Que se trate de dos valores indica claramente que es un error, por lo que eliminamos directamente estos registros. También vemos un valor mínimo de 0 en *Airbags*, que aunque inicialmente puede parecer un error, puede tener sentido si los coches fueran muy antiguos, ya que estos se hacían en algunos casos sin airbags. No haremos nada en este caso. Por último, se ve que la variable de *Levy* y *Mileage* tienen máximos muy elevados, por lo que analizaremos más a fondo los valores atípicos. Para ello, hemos creado la siguiente función, que toma en cuenta el rango intercuartílico para discriminar qué valores son atípicos.

```

1 def detect_outliers(df, column):
2     Q1 = df[column].quantile(0.25)
3     Q3 = df[column].quantile(0.75)
4     IQR = Q3 - Q1
5     lower_bound = Q1 - 1.5 * IQR
6     upper_bound = Q3 + 1.5 * IQR
7     return df[(df[column] < lower_bound) | (df[column] > upper_bound)]

```

Esto nos da un total de 92 outliers en la primera variable y un total de 81 en la segunda variable. Estos datos, un total de 173 valores atípicos (que podrían ser incluso menos, ya que puede que haya una fila que sea atípica en ambas variables) representa apenas un 4% de los datos, por lo que, en lugar de perder tiempo en la imputación de los valores atípicos, se ha decidido optar por eliminarlos directamente. Con esto, ya tenemos todas las variables limpias, así que podemos pasar a realizar el análisis bidimensional frente a la variable target.




Figura 6: Boxplots - Bidimensional vs. target




Figura 7: Curvas de densidad - Bidimensional vs. target




Figura 8: Color por variables categóricas + soporte

El análisis bidimensional frente a la target se ha realizado tanto en base a los boxplots (figura 6) y las densidades (figura 7) para las variables numéricas y las gráficas de tasa con soporte para las categóricas (figura 8). En primer lugar, si analizamos el precio, se observan colas largas hacia la derecha en ambas clases así como la presencia de valores extremos, aunque la mediana de los coches blancos es ligeramente superior a la de los negros. Esto indica que, por lo general, los coches blancos tienden a ser más caros, aunque la diferencia no es muy elevada. Respecto al año de producción, la diferencia es más clara, y es que los coches blancos son más recientes que los negros. El boxplot sitúa a la mediana de los blancos por encima, y la densidad muestra mayor concentración en los años recientes. Por el contrario, variables como el interior de cuero, el cambio, la posición del volante o la presencia de turbo presentan distribuciones casi idénticas por el color, lo cual apunta a que no tienen un poder discriminatorio muy elevado.

En el caso del *engine volume* o los cilindros, los coches negros tienden a tener motores más grandes, lo cual podría ser explicable debido a que son colores que se asocian a los vehículos de alta gama, aunque la diferencia tampoco es excesivamente elevada. Otras variables como el kilometraje y el número de airbags también presentan una distribución bastante similar, con una ligera mayor diferencia en el rango medio. Algo parecido ocurre con *levy*, cuyos valores se solapan bastante entre clases, lo que podría limitar su capacidad predictiva. Por último, la tracción delantera o *front drive* aparece distribuida casi uniformemente entre ambos colores, si bien es cierto que se observa una mayoría de vehículos con tracción delantera.

Respecto a las variables categóricas, aquí tenemos información más relevante. En el caso del fabricante, vemos que la tasa de blancos es de casi la mitad en vehículos de marcas más "baratas", mientras que en marcas más "premium" (como Mercedes) es más reducida. Además, el soporte es amplio, con más de 1000 valores en Hyundai y Toyota, si bien es cierto que la marca Lexus sólo presenta 200 valores. Esto sugiere que el fabricante es claramente una variable informativa. En cuanto a la categoría del vehículo, se aprecia una mayor proporción de blancos en los *hatchback*, de alrededor del 63 %, mientras que la de los sedanes es aproximadamente del 43 %. Aunque el soporte de los *hatchback* es bastante menor al resto, la diferencia en las tasas es relevante y sugiere que la tipología del coche sí tiene relación con el color. Por último, el tipo de combustible, presenta una gran diferencia entre los vehículos a gasolina y los diésel e híbridos, si bien es cierto que en estos dos últimos tenemos muchos menos datos.

En definitiva, los gráficos muestran que las variables categóricas son las que más discriminan en relación con el color del vehículo, mientras que en las numéricas hay más diferencia. El año de producción y el precio son las que más discriminan en este caso, mientras que la mayoría de variables de tipo binario apenas generan diferencias. Sin embargo, antes de decidir si se eliminan estas variables, es preciso realizar un análisis de correlación de variables, y ahí decidir con cuáles nos quedamos y cuáles descartamos, aunque no sin antes crear las variables dummies para las variables categóricas.




Figura 9: Matriz de correlación de las variables

En la imagen 9 tenemos dicha matriz de correlación, en la cual vemos dos cosas que destacan.

En primer lugar, la fuerte correlación positiva entre el número de cilindros y el volumen del motor, con un valor de 0,79. Esto es coherente, ya que a mayor número de cilindros, más potente suele ser el motor. En este caso, ya que se dice que es adecuado eliminar las variables con una correlación superior a 0,8 (tanto negativa como positiva), eliminaremos la variable de *Cylinders*. Por otra parte, tenemos una correlación negativa, aunque más moderada que la anterior, de -0,64, entre el *Front drive* y tanto el volumen del motor como el número de cilindros. Esto también es esperable, ya que los vehículos con tracción delantera suelen tener motores menos potentes. Sin embargo, dado que el valor no supera el umbral definido anteriormente,

no se procederá a eliminar ninguna de estas variables.

Más allá de estas relaciones, que son las destacables, se observan correlaciones de menor magnitud entre variables como el precio y el turbo, o entre el año de producción y el *levy*, lo que sugiere que podría haber ciertos patrones.

Por último, separamos el dataframe en las variables predictoras o independientes y la variable que queremos predecir, y dividimos los datos en entrenamiento y prueba, con un tamaño de prueba del 30 %. A continuación, realizamos una estandarización de los datos. Esto se hace ya que los algoritmos que emplearemos, como es el SVM, es bastante sensible a la escala de los datos, y un rango muy grande en una variable podría hacer que esta sobredomine el modelo. Con esto, ya tenemos los datos listos con los que aplicar el modelo.

2. Modelo de SVM

2.1. Ajuste del modelo

Para crear y ajustar los modelos, se ha optado por probar con los tres tipos de kernels: lineal, polinómico y rbf. El kernel lineal depende únicamente del parámetro de regularización C , que controla el equilibrio entre el margen y los errores de clasificación: valores pequeños de C permiten un margen más amplio a costa de aceptar más errores, mientras que valores grandes penalizan fuertemente los errores, ajustando el modelo más a los datos pero con mayor riesgo de sobreajuste. Este parámetro es común a los tres kernels. En el polinómico, además, se ajustan el grado del polinomio y un término adicional, coef0 , que regula la importancia que tienen los términos de mayor orden con respecto a los de menor orden. Es un kernel útil para relaciones no lineales más complejas, pero conforme aumenta el grado, aumenta el riesgo de sobreajuste. Por último, el rbf o *radial basis function*, incorpora a C el parámetro γ , que regula la influencia de los puntos de entrenamiento: a menor γ , las fronteras de decisión serán más suaves; mientras que en uno más elevado serán más ajustadas a los datos, lo cual también produce riesgo de sobreajuste. En este caso, para cada uno de los kernels, se definen los siguientes parámetros:

```
1 param_grid_linear = {'C': [0.001, 0.01, 0.1, 0.5, 1, 2, 5, 10, 50,
2   100, 200, 500, 1000]}
3 param_grid_poly = {'C': [0.01, 0.1, 0.5, 1, 2, 5, 10], 'degree': [2,
  3, 4, 5], 'coef0': [0, 1, 2, 3]}
param_grid_rbf = {'C': [0.01, 0.1, 1, 10, 100], 'gamma': [0.001,
  0.01, 0.1, 1]}
```

Para ajustar los hiperparámetros, se ha realizado una estrategia en dos etapas: por una parte, se ejecutó una búsqueda gruesa mediante la rejilla de parámetros definida anteriormente, lo cual permite identificar las regiones del espacio de parámetros con mejor rendimiento y acotar los valores. Esto se realizó posteriormente en una búsqueda fina o *fine tuning*. Además, ambas búsquedas se han hecho empleando GridSearchCV, que no sólo evalúa todas las combinaciones posibles de hiperparámetros en la rejilla que se haya definido, sino que lo hace aplicando también validación cruzada. En este caso, es una validación cruzada estratificada, de forma que en cada partición se preserve la proporción original de clases, lo que asegura que el modelo no esté sesgado por una partición en concreto que podría tener mayor concentración de una clase.




Figura 10: Lineal




Figura 11: Polinómico




Figura 12: RBF

Tras el ajuste con grid search, se obtuvieron los mejores parámetros para cada kernel. En la primera iteración de la búsqueda, se vio que, para el kernel lineal, el mejor modelo es el que da con un $C = 0.01$, con un AUC promedio de 0.6850. Para el kernel polinómico, el mejor C es también 0.01, con un polinomio de grado 2 y un coeficiente de 3, que da un AUC de 0.6833. Por último, el kernel RBF tiene el mejor ajuste con $C = 10$ y un $\gamma = .001$. Tras refinar estos valores, el kernel lineal mantuvo su mejor resultado en $C = 0.01$, con un AUC similar, de 0.6856; el kernel polinómico ajustó ligeramente el C a 0.015, obteniendo un AUC de 0.6849; mientras que el RBF ajustó ambos parámetros, teniendo ahora un $C = 5$ y un $\gamma = .0015$ para un AUC de 0.6861. Como se puede ver, las diferencias entre los kernels son mínimas, con AUC muy próximos.

En la figura 13 se ve el `classification_report`, que confirma también esta tendencia, con los tres modelos obteniendo métricas prácticamente idénticas: una precisión de 0.65 para la clase 0 y de 0.60 para la clase 1, junto con un *recall* de 0.57 para la clase 0 y 0.69 para la clase 1. El *f1-score* también se mantiene similar en todos los modelos, con 0.60 para la clase 0 y 0.64 para la clase 1. Además, como se ve en las matrices de confusión (figura ??), los tres modelos muestran resultados similares. En el caso del lineal, presenta un número mayor de falsos positivos (180), aunque consigue un buen número de verdaderos positivos (265) y negativos (227). El modelo polinómico reduce levemente los falsos positivos (176) pero a costa de un ligero aumento en los falsos negativos (122). El RBF presenta prácticamente los mismos resultados que el polinómico, con 176 falsos positivos y 123 falsos negativos, evidenciando un rendimiento muy equilibrado en términos de clasificación.

Classification report LINEAL					Classification report POLINOMIAL					Classification report RBF				
	precision	recall	f1-score	support		precision	recall	f1-score	support		precision	recall	f1-score	support
0	0.65	0.56	0.60	407	0	0.65	0.57	0.61	407	0	0.65	0.57	0.61	407
1	0.60	0.69	0.64	385	1	0.60	0.68	0.64	385	1	0.60	0.68	0.64	385
accuracy			0.62	792	accuracy			0.62	792	accuracy			0.62	792
macro avg	0.62	0.62	0.62	792	macro avg	0.63	0.63	0.62	792	macro avg	0.63	0.62	0.62	792
weighted avg	0.63	0.62	0.62	792	weighted avg	0.63	0.62	0.62	792	weighted avg	0.63	0.62	0.62	792


Figura 13: *Classification report* para SVM

Figura 14: Kernel lineal




Figura 15: Kernel polinómico




Figura 16: Kernel gaussiano

Además, mostramos también el área bajo la curva ROC, que en este caso se ha decidido hacer de forma conjunta para los tres modelos, como se ve en la imagen 17. Esto nos sirve para evaluar también el rendimiento del modelo, ya que muestra la relación entre FP y TP. Un valor próximo a 1 indica un rendimiento perfecto, mientras que menor que 0,5 indica que es peor que el azar, que clasifica al revés y mal. En este caso, el mejor valor del AUC es el del RBF, con 0.656, mientras que el peor es el del lineal, con 0.652, y el polinómico se sitúa en medio, con 0.654,

aunque la diferencia entre todos ellos es muy pequeña, de apenas 0.004, lo cual no es relevante.




Figura 17: Área bajo la curva ROC

Para elegir el mejor modelo empleamos estos tres indicadores: las matrices de confusión, la *accuracy* y el área bajo la curva ROC. Como se ha visto, los tres modelos presentan un rendimiento equivalente y, de hecho, el incremento de rendimiento del RBF respecto al lineal es marginal, mientras que el coste computacional y la complejidad del modelo es muy superior. Por ello, aunque al realizar una selección automática mediante GridSearchCV nos diga que el mejor modelo es el RBF, es necesario aplicar el principio de parsimonia, considerando las pequeñas diferencias en el *accuracy* es tan pequeña que se puede justificar la elección del modelo lineal como el mejor: ofrece un rendimiento idéntico y con un modelo mucho más sencillo, más fácil de interpretar y más rápido de entrenar.

2.2. Aplicación de bagging

El bagging, o bootstrap aggregating, es una técnica de ensamblaje de modelos diseñada para reducir la varianza y mejorar la estabilidad de los algoritmos de aprendizaje automático. Se basa en entrenar múltiples modelos base sobre subconjuntos generados por remuestreo, o *bootstrap*, de los datos originales y, posteriormente, combinar sus predicciones mediante votación, en este caso, ya que se trata de un problema de clasificación. Esto permite suavizar las fluctuaciones propias de cada uno de los modelos individuales, así como mejorar la capacidad de generalización y, en casos, acelerar el entrenamiento, ya que se divide la carga entre varios estimadores.

En este caso se aplica un BaggingClassifier con el modelo lineal como modelo base. Para ajustarlo, se ha realizado también una búsqueda en una rejilla de hiperparámetros, explorando distintas combinaciones del número de estimadores, la fracción de muestras utilizada en cada remuestreo y la proporción de características usadas. El mejor conjunto de parámetros resultó

ser `n_estimators=100`, `max_samples=1.0`, `max_features=0.7`, alcanzando un AUC promedio de 0.6867, ligeramente superior al del modelo base.

```

1  "n_estimators": [10, 30, 50, 100, 150]
2  "max_samples": [0.5, 0.7, 1.0]
3  "max_features": [0.5, 0.7, 1.0]
4  "bootstrap": [True]
5  "bootstrap_features": [False]

```

Al evaluar sobre test, el modelo de bagging obtiene una *accuracy* del 61,7% y un AUC de 0.654, frente al 62,1% y 0.652 del modelo base. Esto indica que la mejora es marginal: el AUC se incrementa levemente, y la exactitud disminuye unas décimas. La matriz de confusión (figura 19) refleja este comportamiento: el bagging incrementa los verdaderos negativos de los 227 del base a 250, pero a costa de aumentar los falsos negativos, que pasan de 120 a 146. El reporte de clasificación (figura 18) confirma esto: la clase 0 alcanza una precisión de 0.63 y recall de 0.61, mientras que la clase 1 obtiene 0.60 y 0.62 respectivamente. En ambos casos, el f1-score es similar, de 0.61 y 0.62. En conclusión, la aplicación del bagging no supone una mejora sustancial del rendimiento global y, dado el coste adicional de entrenar 100 clasificadores, no parece que compense la complejidad añadida.

Classification report – Bagging					
	precision	recall	f1-score	support	
0	0.63	0.61	0.62	407	
1	0.60	0.62	0.61	385	
accuracy			0.62	792	
macro avg	0.62	0.62	0.62	792	
weighted avg	0.62	0.62	0.62	792	

Figura 18: Classification report, accuracy y AUC para bagging




Figura 19: Matriz de confusión para bagging

3. Modelo de stacking en profundidad

El stacking es una técnica de ensamblaje que combina distintos modelos, llamados modelos base, con un metaclasificador, para crear un modelo final que mejore el rendimiento, aprovechando las virtudes de cada modelo. La idea es que, si los modelos base cometen errores distintos, el metaclasificador aprenda a corregirlos y produzca un modelo más robusto. En nuestro caso, hemos elegido cuatro modelos base: Random Forest, Logistic Regression y K-Neighbors, así como el ejor SVM. Como metaclasificador, se ha usado una Regresión Logística, para evitar un sobreajuste excesivo y mantener la interpretabilidad.

- **Random Forest** se basa en árboles de decisión, entrenando cada árbol con una muestra aleatoria de los datos. En cada nodo, el árbol seleccionará la mejor característica para dividir los datos, empleando un criterio concreto, y combina la predicción individual de cada uno de los árboles. Su principal ventaja es su robustez y su versatilidad.
- **Logistic Regression** se usa principalmente para tareas de clasificación binaria, por lo que es un modelo que no podía faltar. Utiliza una función con la cual combina linealmente cada una de las características de entrada en una probabilidad, que representa la clase de salida, para la cual se establece un umbral al partir del cual se considera una clase u otra. Su principal ventaja es su simplicidad y eficiencia, así como que predice probabilidades, pero no es adecuado si no hay relaciones lineales entre las variables.
- **K-Nearest Neighbors** (o **KNN**) se basa en instancias, clasificando una instancia en base a los k vecinos más cercanos a la misma. Este modelo calcula las distancias entre la instancia o dato de prueba y los de entrenamiento para realizar una predicción, selecciona los k vecinos más cercanos y predice la clase más común entre ellos. No realiza un entrenamiento explícito, sino que se "guarda" los datos de entrenamiento y va clasificando en función de ellos. Su principal ventaja es la facilidad que tiene para entenderlo, que no es paramétrico y que es ideal para captar patrones locales

Un aspecto clave para la efectividad del stacking es usar clasificadores base diversos. La tabla de correlación de predicciones (figura 20) muestra que, en general, las correlaciones están en valores moderados, en torno al 0.5-0.6, lo que implica que los modelos aportan cierta diversidad. Sí que se observa una correlación bastante elevada entre LR y el modelo base, del 0.826, lo que indica que tienen a producir predicciones muy similares y podría reducir la ganancia al combinarlos en un stacking.

Los resultados de los modelos base y del stacking se evaluaron, de igual forma que en los casos anteriores, mediante accuracy, AUC y matrices de confusión. El Random Forest obtiene el mejor equilibrio entre precisión y recall, con un accuracy en test del 0.65 y un AUC de 0.69, mostrando un buen balance entre verdaderos positivos y negativos (figura ??, superior izquierda). La Logistic Regression y el KNN obtuvieron resultados algo más bajos, con un accuracy cerca del 0.63 y un AUC ligeramente inferior. El SVM, por su parte, logró un rendimiento bastante similar. Al combinar los modelos en stacking, se observa un incremento en el AUC test al 0.709 y, además, en la matriz de confusión (figura ??, inferior derecha) se aprecia una reducción de los falsos negativos y una clasificación más equilibrada entre ambas clases. En general, el stacking mejora el AUC, pero no tanto el accuracy. Esto es algo general en

```

=== Correlación entre predicciones de clasificadores base (TEST) ===
rf      1.000000  0.529537  0.580584  0.501686
lr      0.529537  1.000000  0.599400  0.826463
knn     0.580584  0.599400  1.000000  0.600672
svm     0.501686  0.826463  0.600672  1.000000

```

Figura 20: Correlación de los modelos base




Figura 21: Matrices de confusión para stacking

stacking: el AUC suele ser la métrica más beneficiada, mientras que las ganancias en accuracy suelen ser más modestas.

4. Comparativa y conclusiones

El estudio comparativo de los modelos nos permite extraer varias consideraciones de interés. En primer lugar, la homogeneidad en el rendimiento global ya que, como se observa en la figura 22, todos los modelos alcanzan métricas similares, con un *accuracy* en torno al 0.64 y un AUC entre 0.65 y 0.71. Esto refleja que los límites predictivos están condicionados no tanto por la elección del algoritmo, sino más por la calidad de los datos. Una posible mejora sería probar con distintas combinaciones de variables, para ver cuál nos ofrece un mejor rendimiento. Dentro de esto, si bien los tres tipos de kernel han obtenido resultados similares, se destaca el kernel lineal por, aún siendo realmente simple, producir unos resultados igual de buenos que el resto.




Figura 22: Gráfico comparativo de métricas

Modelo	Accuracy (Test)	AUC (Test)	F1-score (Test)	Acc Gap	AUC Gap
SVM base	0.621	0.652	0.639	0.019	0.039
Bagging SVM	0.617	0.654	0.612	0.036	0.037
Base-RF	0.650	0.699	0.638	0.350	0.301
Base-LR	0.626	0.665	0.626	0.031	0.033
Base-KNN	0.630	0.688	0.621	0.067	0.069
Base-SVM	0.621	0.652	0.639	0.019	0.039
Stacking (LR)	0.636	0.709	0.638	0.224	0.237

Cuadro 1: Resultados comparativos en test para los modelos evaluados

Respecto a las técnicas de mejora de los modelos, en ensamblado mediante *bagging* no logra una mejora significativa respecto al SVM base ya que, pese a aumentar el AUC, lo hace a costa de reducir el *accuracy* y el F1. Esto significa que el problema no es lo suficientemente estable como para poder beneficiarse de técnicas de agregación. Respecto al stacking, consigue la mejor puntuación de AUC, reflejando la capacidad que tiene para combinar la información de los distintos clasificadores base. Sin embargo, presenta un alto AUC en *train*, lo cual podría ser una señal de sobreajuste. Dentro de los modelos base que se emplearon, el Random Forest obtiene el mejor equilibrio entre *test* accuracy y AUC, pero presenta un alto gap entre el AUC de *train* y *test*, indicando también un riesgo de sobreajuste. El Logistic Regression, por su parte, tiene resultados similares al SVM, con la ventaja de una alta interpretabilidad. Por último, el KNN está en una situación intermedia, con un buen AUC pero menor estabilidad. En resumen,

el realizar un stacking mejora marginalmente los resultados, pero a costa de incrementar la complejidad del modelo.

En relación con el sobreajuste, algunos modelos presentan cierto gap entre las métricas de entrenamiento y test, como es el caso del stacking que, como se ve en la tabla 1 obtiene un 0.946 en entrenamiento, frente al 0.709 de test, lo cual representa un gap de 0.237. Esta es la mayor diferencia entre todos los modelos, lo cual refleja un ajuste excesivo a los datos de entrenamiento y una menor capacidad de generalización, y presenta problemas de estabilidad al enfrentarse a nuevos datos. Por el contrario, el comportamiento del SVM lineal es más equilibrado, con una diferencia muy reducida (AUC de 0.691 en train y 0.652 en test), lo que refleja un modelo más robusto y generalizable.

La elección del modelo debe guiarse por un equilibrio entre rendimiento y parsimonia. Aunque los métodos de ensamblado como Bagging y Stacking ofrecen ligeras mejoras en algunas métricas (por ejemplo, el Stacking logra el mayor AUC en test), estas mejoras son modestas y se acompañan de un incremento considerable en la complejidad y el riesgo de sobreajuste. El Random Forest, a pesar de su buena precisión en test, queda penalizado por su alto riesgo de overfitting. En este contexto, el SVM lineal emerge como la opción más adecuada: mantiene un rendimiento competitivo en todas las métricas (accuracy de 0.621, AUC de 0.652 y F1-score de 0.639 en test), con un comportamiento estable entre entrenamiento y test, un bajo riesgo de sobreajuste y la ventaja adicional de su simplicidad e interpretabilidad.

En conclusión, los resultados muestran que las mejoras obtenidas por los modelos más complejos (Random Forest, Bagging, Stacking) son marginales y no compensan el aumento de complejidad y el mayor riesgo de sobreajuste. Aplicando el principio de parsimonia, y teniendo en cuenta los resultados obtenidos en la figura 22 y en la tabla 1, el SVM lineal es el modelo más recomendable, ya que logra un equilibrio óptimo entre rendimiento predictivo, estabilidad, interpretabilidad y capacidad de generalización. Se trata, por tanto, del modelo más apropiado para abordar este problema en un entorno práctico.